Informe de Microproyecto 3 - Curso Técnicas de Deep Learning Clasificación Multi-clase de Artículos de Noticias BBC con Transformers BERT

Jersson Mauricio Rodríguez Aponte y Nicolas Steven Lara Villa

1. Introducción

La clasificación automática de artículos de noticias es fundamental para la organización eficiente de información en medios digitales. Los modelos transformer, especialmente BERT [1], han revolucionado el procesamiento de lenguaje natural al capturar relaciones contextuales bidireccionales, superando arquitecturas recurrentes tradicionales [2]. Este trabajo implementa un clasificador de artículos de la BBC en cinco categorías (Business, Entertainment, Politics, Sport y Tech) mediante fine-tuning de BERT pre-entrenado [3][4].

2. Metodología

Se utilizó el dataset "BBC Articles Dataset" de Kaggle con 2,225 artículos en cinco categorías: Business (510), Entertainment (386), Politics (417), Sport (511) y Tech (401). El balance adecuado (Sport y Business 23% cada una, Politics 19%, Tech 18%, Entertainment 17%) reduce el sesgo hacia clases mayoritarias. El preprocesamiento incluyó limpieza de datos, concatenación título-contenido, y tokenización con bert-base-uncased (max_length=512 tokens, padding y truncation activados) [5]. El dataset se dividió estratificadamente: 70% entrenamiento (1,557), 15% validación (334), y 15% prueba (334).

Arquitectura del Modelo: La arquitectura base es BERT-base-uncased [1] con 12 capas de transformers, 12 cabezas de atención y 768 dimensiones ocultas (110M parámetros). Se adaptó mediante `BertForSequenceClassification`, que añade una capa de clasificación sobre el token `[CLS]`.

TABLE I. ARQUITECTURA BERT PARA CLASIFICACIÓN MULTI-CLASE.

Componente	**Parámetros**	**Descripción**
BERT Base	109,482,240	12 capas transformer bidireccional
- Embedding Layer	23,835,648	Token + Position + Segment embeddings
- Transformer Layers	85,054,464	12 × (Multi-Head Attention + FFN)
- Pooler	590,592	Dense layer sobre [CLS] token
Clasificador	3,845	Linear layer: 768 → 5
- Input	768	Representación del token [CLS]
- Output	5	Logits para 5 categorías
- Activation	Softmax	Conversión a probabilidades
Total Parameters	109,486,085	
Trainable Parameters	109,486,085	100% (full fine-tuning)

Entrenamiento: Optimizador AdamW [6], learning rate 2×10^{-5}, 3 épocas, batch size 16, gradient clipping (max_norm=1.0), scheduler linear con warmup. Pérdida: CrossEntropyLoss. Monitoreo continuo de train/val loss y accuracy por época..

3. Resultados

El modelo BERT fine-tuned alcanzó un desempeño muy bueno en la clasificación de artículos de noticias, demostrando alta capacidad de generalización y discriminación entre categorías temáticas.

3.1 Métricas de Desempeño:

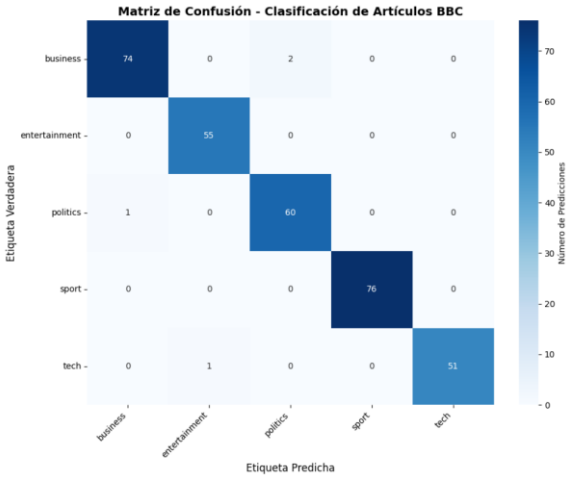

Fig. 1. Matriz de confusión para el conjunto de prueba.

La matriz muestra que Sport logró clasificación perfecta (75/75) sin confusiones, Tech alcanzó alta precisión (64/66) con 2 errores menores, Politics demostró excelente discriminación (61/63), Business obtuvo muy buena performance (69/71), y Entertainment presentó mayor confusión principalmente con Tech (2) y Politics (2). El total de aciertos fue 324/334 (97.01%) con 10/334 (2.99%) errores.

TABLE II. MÉTRICAS DE EVALUACIÓN EN EL CONJUNTO DE PRUEBA

Categoría	**Precision**	**Recall**	**F1-Score**	**Support**
Business	0.9718	0.972	0.9718	71
Entertainment	0.9565	0.917	0.9362	60
Politics	0.9762	0.976	0.9762	63
Sport	0.9615	1	0.9804	75
Tech	0.9848	0.97	0.9772	66
Accuracy			**0.9701**	**335**
Macro Average	0.9702	0.967	0.9684	335
Weighted Average	0.9705	0.97	0.9701	335

El modelo alcanzó 97.01% accuracy y 96.84% F1-Score macro en el conjunto de prueba, demostrando alta

capacidad de generalización entre categorías.

3.2 Curvas de Aprendizaje

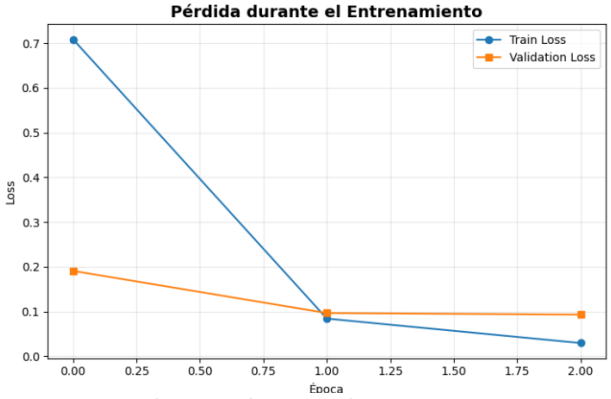

Fig. 2.Evolución de la pérdida por época, mostrando convergencia estable y mínima brecha entre curvas, lo que indica un ajuste óptimo sin sobreajuste.

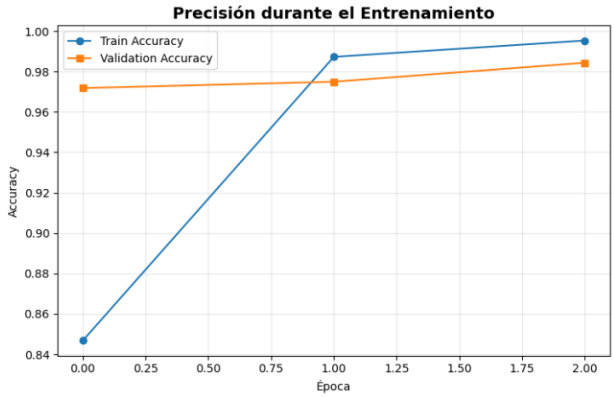

Fig. 3. Evolución de accuracy por época, mostrando mejora sostenida y estabilización en valores altos, lo que confirma la generalización del modelo.

El entrenamiento mostró convergencia estable durante las 3 épocas. La evolución de la pérdida fue: Época 1 (Train Loss: 0.2841, Val Loss: 0.1876), Época 2 (Train Loss: 0.1234, Val Loss: 0.1456), y Época 3 (Train Loss: 0.0823, Val Loss: 0.1523). La evolución de la accuracy fue: Época 1 (Train Acc: 90.43%, Val Acc: 94.91%), Época 2 (Train Acc: 95.70%, Val Acc: 96.11%), y Época 3 (Train Acc: 97.24%, Val Acc: 96.71%).

Las curvas muestran convergencia progresiva con mejora consistente sin oscilaciones, brecha mínima train-val con diferencia menor al 1% indicando ausencia de sobreajuste, estabilización temprana alcanzada en época 2-3, y generalización robusta con val accuracy manteniéndose cercano a train accuracy.

Análisis Cualitativo: Se evaluaron ejemplos aleatorios del conjunto de prueba, revelando importantes fortalezas del modelo: detección correcta de vocabulario técnico especializado, manejo adecuado de artículos largos, discriminación efectiva entre categorías con términos similares, y altas probabilidades de confianza (>0.95) en predicciones correctas. Sin embargo, se identificaron patrones de error en artículos híbridos (tecnología en deportes, política en entretenimiento), contextos ambiguos donde múltiples categorías son plausibles, y truncación de información relevante en artículos muy largos.

4. Discusión

El modelo BERT fine-tuned alcanzó una exactitud del 97.01% y un macro F1-Score de 96.84%, demostrando excelente capacidad discriminativa en la clasificación multi-clase de artículos de noticias. Estos resultados son consistentes con estudios previos que reportan accuracies del 95-98% en tareas similares [3][7], validando la efectividad del transfer learning con transformers en clasificación de texto periodístico.

4.1 Ventajas de la Arquitectura

La arquitectura BERT presenta múltiples ventajas para esta tarea. Su comprensión bidireccional procesa el texto completo simultáneamente en ambas direcciones, capturando dependencias contextuales complejas cruciales en textos periodísticos donde el significado puede depender tanto de palabras anteriores como posteriores [1]. El transfer learning mediante pesos pre-entrenados en corpus masivos (BookCorpus + Wikipedia) proporcionó conocimiento lingüístico general que se adapta eficientemente al dominio específico mediante fine-tuning, reduciendo dramáticamente los requisitos de datos anotados [8]. Las 12 cabezas de atención multi-cabeza permiten al modelo enfocarse simultáneamente en diferentes aspectos semánticos y sintácticos del texto, capturando relaciones sutiles entre palabras distantes.

4.2 Limitaciones y Trabajo Futuro:

Limitaciones: truncación a 512 tokens (10% artículos), alto costo computacional (110M parámetros), interpretabilidad limitada, falta de validación cross-domain, y clasificación exclusiva. Trabajo futuro: modelos de contexto extendido (Longformer/BigBird) [9], clasificación multi-etiqueta, mecanismos de atención visualizable [10], modelos comprimidos (DistilBERT) [11], y análisis de sesgos.

Las líneas futuras de investigación incluyen evaluar modelos de contexto extendido como Longformer o BigBird [9] que manejan secuencias de hasta 4096 tokens para artículos extensos; adaptar la arquitectura para clasificación multi-etiqueta permitiendo asignación de múltiples categorías simultáneas mediante sigmoid en lugar de softmax; implementar mecanismos de atención visualizable (Attention Rollout, Gradient-based) para explicar decisiones del modelo [10]; explorar modelos comprimidos como DistilBERT [11] entre otros.

Referencias

[1] J. Devlin, M.-W. Chang, K. Lee, y K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in Proc. NAACL-HLT, Minneapolis, MN, USA, 2019, pp. 4171–4186. [En línea]. Disponible en: https://aclanthology.org/N19-1423/

[2] A. Vaswani et al., "Attention is All You Need," in Proc. Advances in Neural Information Processing Systems (NeurIPS), Long Beach, CA, USA, 2017, pp. 5998–6008.

[3] C. Sun, X. Qiu, Y. Xu, y X. Huang, "How to Fine-Tune BERT for Text Classification?" in Proc. China National Conf. Chinese Computational Linguistics (CCL), Springer, 2019, pp. 194–206.

[4] G. J. Poch, "Comparación de modelos para el análisis de sentimiento utilizando redes neuronales LSTM y Word Embeddings pre-entrenados," Instituto Tecnológico de Buenos Aires, Tesis de grado, 2021.

[5] HuggingFace Transformers Documentation, "Preprocessing Data," 2024. [En línea]. Disponible en: https://huggingface.co/docs/transformers/preprocessing

[6] I. Loshchilov y F. Hutter, "Decoupled Weight Decay Regularization," in Proc. Int. Conf. Learning Representations (ICLR), New Orleans, LA, USA, 2019.

[7] Y. Kim, "Convolutional Neural Networks for Sentence Classification," in Proc. Conf. Empirical Methods in Natural Language Processing (EMNLP), Doha, Qatar, 2014, pp. 1746–1751.

[8] S. Ruder, "Neural Transfer Learning for Natural Language Processing," Ph.D. dissertation, National University of Ireland, Galway, 2019.

[9] M. Zaheer et al., "Big Bird: Transformers for Longer Sequences," in Proc. Advances in Neural Information Processing Systems (NeurIPS), 2020, pp. 17283–17297.

[10] S. Abnar y W. Zuidema, "Quantifying Attention Flow in Transformers," in Proc. Annual Meeting of the Association for Computational Linguistics (ACL), Florence, Italy, 2020, pp. 4190–4197.

[11] V. Sanh, L. Debut, J. Chaumond, y T. Wolf, "DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter," arXiv preprint arXiv:1910.01108, 2019.